



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS
PRÓ-REITORIA DE ENSINO
CÂMPUS GOIÂNIA
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

WARLEY RODRIGUES DE ANDRADE

Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

Uma pipeline temporal para previsão de notas,
identificação de risco acadêmico e geração de
relatórios escolares

Goiânia, 2026.

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS

PRÓ-REITORIA DE ENSINO

CÂMPUS GOIÂNIA

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

WARLEY RODRIGUES DE ANDRADE

Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

**Uma pipeline temporal para previsão de notas,
identificação de risco acadêmico e geração de
relatórios escolares**

Trabalho de Conclusão de Curso apresentado à Coordenação do Curso de Bacharelado em Sistemas de Informação como requisito parcial para obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Otávio Xavier Calaça

Goiânia, 2026.

Obs: Após defesa e correção, imprimir da capa ao sumário e entregar na biblioteca ou encaminhar email, solicitando a elaboração da Ficha Catalográfica
email para orientação de elaboração da FICHA CATALOGRÁFICA
bib.goiania@ifg.edu.br (biblioteca do IFG)

Modelo:

A654

Aproveitamento da água pluvial como uma alternativa para substituição da água tratada nas instalações da SANEAGO : uma proposta de gerenciamento ambiental para o distrito norte / Elcio Vânio de Oliveira et al. – Goiânia, 2009.
00f. : il.

Orientadora: Profª Drª Warde Antonieta da Fonseca-Zang
Co-orientador; Profª. Dr. Joachim Werner Zang.

Dissertação de Mestrado – Mestrado Profissional em Tecnologia de Processos Sustentáveis, Instituto Federal de Educação, Ciência e Tecnologia de Goiás.

1. Água pluvial – aproveitamento e alternativa 2. SANEAGO – tratamento de água – 4. Gerenciamento ambiental I. Fonseca-Zang, Warde Antonieta da (orientadora) II. Instituto Federal de Educação, Ciência e Tecnologia de Goiás, Mestrado em Tecnologia de Processos Sustentáveis.

1

CDD 363.700 817 3

2

Ficha catalográfica elaborada pelo responsável da Biblioteca Professor Jorge Félix de Souza,
Instituto Federal de Educação, Ciência e Tecnologia de Goiás

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS
PRÓ-REITORIA DE ENSINO
CÂMPUS GOIÂNIA
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

WARLEY RODRIGUES DE ANDRADE

Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

Uma pipeline temporal para previsão de notas,
identificação de risco acadêmico e geração de
relatórios escolares

Trabalho de Conclusão de Curso defendido no Curso de Bacharelado em Sistemas de Informação como requisito parcial para obtenção do título de Bacharel em Sistemas de Informação, aprovada em 21 de Abril de 2026, pela Banca Examinadora constituída pelos professores:

Prof. Dr. Otávio Xavier Calaça
IFG / Câmpus Goiânia
Orientador

Prof. Dr. Fulano de Tal
Instituição

Profa. Dra. Fulana de Tal
Instituição

Resumo

Título: Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

Autor: Warley Rodrigues de Andrade

Orientador: Prof. Dr. Otávio Xavier Calaça

Este Trabalho de Conclusão de Curso apresenta o desenvolvimento de um sistema preditivo voltado ao contexto escolar. O objetivo é antecipar dificuldades acadêmicas e apoiar a tomada de decisão de professores, coordenação pedagógica e secretaria. O problema investigado consiste em verificar se dados históricos de notas, faltas, pagamentos e informações acadêmicas podem ser integrados em uma arquitetura analítica capaz de prever a próxima nota do aluno e identificar sinais de risco pedagógico antes de reprovações ou quedas severas de desempenho. O projeto começou com uma abordagem baseada em grafos, mas evoluiu para uma estratégia temporal tabular após análises indicarem maior aderência entre o problema e modelos supervisionados aplicados a dados longitudinais. A solução final foi organizada no pacote `school_predictor`, com separação entre camada privada de preparação e extração do banco, interface pública baseada em arquivos CSV, engenharia de atributos, validação temporal, seleção de modelos, análise de erro e geração de relatórios. Foram comparados baselines, Random Forest e HistGradientBoosting para regressão da próxima nota e classificação de risco de nota inferior a 6,0. Na previsão numérica, o melhor cenário usou histórico mínimo de uma observação por disciplina e alcançou MAE de 0,7659. No alerta de risco, o melhor cenário usou histórico mínimo de duas observações, alcançando F1 de 0,7436 e recall de 0,8794 no teste temporal. Além da modelagem, foi desenvolvida uma camada de relatórios escolares para professor, coordenação e secretaria, incluindo ranking executivo de alunos prioritários. Conclui-se que uma arquitetura temporal orientada ao uso institucional, acompanhada de interpretação, priorização e proteção de dados, pode apoiar intervenções pedagógicas mais precoces.

Palavras-chave

mineração de dados educacionais; previsão de desempenho escolar; aprendizado de máquina; risco pedagógico; learning analytics; modelagem temporal tabular.

Abstract

Title: Predictive system for school performance to support pedagogical decision-making

Author: Warley Rodrigues de Andrade

Advisor: Prof. Dr. Otávio Xavier Calaça

This undergraduate thesis presents the development of a predictive system for school environments. Its goal is to anticipate academic difficulties and support decision-making by teachers, pedagogical coordinators, and administrative staff. The research problem investigates whether historical school data, such as grades, absences, payments, and academic records, can be integrated into an analytical architecture capable of predicting a student's next grade and identifying pedagogical risk signals before failure or severe performance decline occurs. The project initially explored a graph-based approach, but evolved into a tabular temporal strategy after the analyses indicated stronger adherence between the problem and supervised models applied to longitudinal data. The final solution was organized around the `school_predictor` package, with a private local layer for database preparation and extraction, a public CSV-based interface, feature engineering, temporal validation, model selection, error analysis, and report generation. Baselines, Random Forest, and HistGradientBoosting were compared for both next-grade regression and classification of risk for grades below 6.0. For numeric next-grade prediction, the best setting used a minimum history of one prior observation per subject and achieved MAE of 0.7659. For risk alerting, the best setting used a minimum history of two prior observations, achieving F1 of 0.7436 and recall of 0.8794 in temporal testing. In addition to predictive modeling, a school reporting layer was developed with outputs for teachers, coordination, and school administration, including an executive ranking of priority students. The study concludes that a temporal analytical architecture oriented toward institutional use, combined with interpretation, prioritization, and data protection mechanisms, can support earlier pedagogical intervention.

Keywords

educational data mining; student performance prediction; machine learning;
pedagogical risk; learning analytics; tabular temporal modeling.

Sumário

1	Introdução	9
1.1	Objetivos.....	9
1.2	Justificativa	10
1.3	Delimitação do tema	10
1.4	Estrutura do trabalho.....	11
2	Fundamentação Teórica e Trabalhos Relacionados	12
2.1	Mineração de Dados Educacionais e Learning Analytics.....	12
2.2	Previsão de desempenho escolar	12
2.3	Modelos de aprendizado de máquina no projeto	13
2.3.1	Random Forest.....	13
2.3.2	LSTM	13
2.3.3	Gradient Boosting.....	13
2.3.4	Classificação supervisionada e regras simples.....	14
2.4	Dados temporais, validade e métricas.....	14
2.5	Ética, privacidade e interpretabilidade.....	15
2.6	Trabalhos relacionados	15
3	Materiais, Métodos e Evolução do Projeto	16
3.1	Natureza da pesquisa	16
3.2	Fonte de dados e preparo inicial	16
3.3	Estratégia metodológica	17
3.4	Evolução histórica do projeto	17
3.4.1	Fase inicial orientada a grafo.....	17
3.4.2	Fase exploratória com testes clássicos e PCA	17
3.4.3	Fase temporal com LSTM	17
3.4.4	Fase tabular com Random Forest	18
3.4.5	Refatoração para pipeline real	18
3.5	Critérios de avaliação	18
4	Arquitetura da Solução e Integração dos Dados	19
4.1	Visão geral da arquitetura	19
4.2	Modos de execução.....	19
4.3	Integração de notas, faltas, pagamentos e professores.....	20
4.4	Engenharia de atributos	21
4.5	Construção do alvo e prevenção de vazamento.....	22
4.6	Camada de relatórios	22
4.7	Estrutura final do repositório e do fluxo operacional	22

5	Modelagem, Relatórios e Resultados	24
5.1	Modelos candidatos e critérios de seleção	24
5.2	Comparação dos candidatos na validação	24
5.3	Resultados do modo de previsão de nota	25
5.4	Resultados do modo de alerta de risco	26
5.5	Comparando históricos mínimos	27
5.6	Exemplo interpretado de alerta	27
5.7	Geração de relatórios escolares.....	28
5.8	Análise de erro e calibração	28
6	Discussão, Limitações e Conclusão	30
6.1	Discussão dos resultados	30
6.2	Limitações do trabalho.....	30
6.3	Conclusão	31
6.4	Trabalhos futuros	31
	Referências	33
	Apêndice A – Estrutura resumida da solução	35
A.1	Organização do repositório.....	35
A.2	Módulos centrais da pipeline.....	35
A.3	Artefatos principais gerados	36

Introdução

O contexto escolar produz diariamente um volume expressivo de dados acadêmicos, administrativos e operacionais. Notas, faltas, registros financeiros, turmas, séries e históricos disciplinares são continuamente armazenados pelos sistemas institucionais, mas nem sempre transformados em informação útil para a tomada de decisão pedagógica. Este trabalho parte justamente dessa lacuna: a escola registra muito, mas ainda utiliza pouco esse conjunto de dados para antecipar dificuldades de aprendizagem e organizar intervenções mais precoces.

Na rotina escolar, boa parte das intervenções acontece de forma reativa. Em geral, professores, coordenação e secretaria percebem o problema quando o aluno já apresenta queda acentuada de desempenho, ausências recorrentes ou risco concreto de reprovação. Nesse momento, a margem de ação é menor e o custo institucional tende a ser maior. Diante disso, este Trabalho de Conclusão de Curso (TCC) investiga se os dados históricos já disponíveis na escola podem ser utilizados para antecipar sinais de risco acadêmico.

O problema central deste trabalho pode ser sintetizado da seguinte forma: como integrar dados escolares históricos de notas, faltas, pagamentos e registros acadêmicos em uma pipeline preditiva capaz de antecipar a próxima nota do aluno e sinalizar risco pedagógico, produzindo relatórios úteis para a tomada de decisão institucional? A partir dessa formulação, o trabalho foi orientado pela hipótese de que uma arquitetura analítica temporal, sustentada por dados tabulares e validação cronológica, seria mais aderente ao problema real do que abordagens puramente relacionais ou experimentos isolados.

1.1 Objetivos

O objetivo geral do trabalho é desenvolver uma pipeline preditiva baseada em dados escolares reais para prever a próxima nota do aluno, identificar risco pedagógico e gerar relatórios operacionais de apoio à decisão para professores, coordenação e secretaria.

Como objetivos específicos, o trabalho busca:

1. investigar a viabilidade de diferentes abordagens computacionais para o domínio escolar;
2. estruturar um fluxo de manutenção, anonimização e extração da base institucional;
3. integrar dados de notas, faltas, pagamentos e contexto acadêmico em uma base longitudinal;
4. construir atributos temporais capazes de representar a trajetória recente do aluno;
5. comparar modelos e baselines com validação temporal;
6. transformar as saídas técnicas em relatórios compreensíveis para a escola.

1.2 Justificativa

O trabalho se justifica em três planos complementares. No plano acadêmico, dialoga com as áreas de Educational Data Mining (EDM) e Learning Analytics (LA), mostrando como um problema institucional real pode ser tratado por meio de integração de dados, modelagem e geração de artefatos operacionais (Romero; Ventura, 2010; Baker; Inventado, 2014; Siemens; Baker, 2012). No plano tecnológico, a contribuição está em sair de experimentos isolados e consolidar uma pipeline reproduzível. No plano social e educacional, a relevância está na possibilidade de apoiar intervenções mais precoces, antes que o aluno atinja um quadro de maior gravidade.

Também existe justificativa ética. Em educação, sistemas preditivos não devem substituir o julgamento pedagógico humano, mas sim apoiar a priorização e a leitura do contexto. Por isso, o sistema proposto foi concebido como ferramenta de apoio à decisão e não como mecanismo automático de julgamento.

1.3 Delimitação do tema

Este trabalho não trata de evasão escolar em sentido amplo, nem pretende substituir os processos formais de avaliação da escola. O foco está na previsão da próxima nota e na identificação de risco pedagógico de curto prazo, com base em registros institucionais já existentes. A pesquisa também se limita aos dados disponíveis no banco escolar analisado e às rotinas que puderam ser tratadas, anonimizadas e extraídas para a pipeline.

1.4 Estrutura do trabalho

Esta monografia foi organizada em seis capítulos. O Capítulo 1 apresenta o problema, os objetivos e a justificativa. O Capítulo 2 discute a fundamentação teórica e os trabalhos relacionados. O Capítulo 3 descreve a natureza da pesquisa e a evolução histórica do projeto. O Capítulo 4 detalha a arquitetura proposta, a integração dos dados e a construção do dataset. O Capítulo 5 apresenta a modelagem, os relatórios e os resultados experimentais. Por fim, o Capítulo 6 discute limitações, conclusões e trabalhos futuros.

Fundamentação Teórica e Trabalhos Relacionados

2.1 Mineração de Dados Educacionais e Learning Analytics

A Mineração de Dados Educacionais (EDM) dedica-se ao desenvolvimento de métodos para explorar dados oriundos de contextos educacionais com o objetivo de compreender, monitorar e melhorar processos de aprendizagem (Romero; Ventura, 2010; Romero *et al.*, 2010). De forma complementar, Learning Analytics (LA) enfatiza a medição, coleta, análise e relato de dados sobre aprendizes e seus contextos para apoiar decisões pedagógicas e institucionais (Siemens; Baker, 2012; Baker; Inventado, 2014).

Neste trabalho, essas duas perspectivas aparecem de forma integrada. Do lado de EDM, o projeto constrói atributos, testa modelos supervisionados e compara métricas. Do lado de LA, o foco está em converter resultados analíticos em relatórios compreensíveis para uso escolar.

2.2 Previsão de desempenho escolar

Prever desempenho escolar pode assumir diferentes formas: prever evasão, reprovação, engajamento, necessidade de reforço ou nota futura. Este trabalho escolhe como foco principal a previsão da próxima nota, porque esse alvo preserva granularidade pedagógica e permite intervenções mais precoces. Em paralelo, a nota prevista é convertida em um alerta de risco, representado por nota futura abaixo de 6,0, o que aproxima a modelagem do uso institucional.

2.3 Modelos de aprendizado de máquina no projeto

O projeto avaliou modelos supervisionados adequados a dados tabulares, com histórico irregular entre alunos, disciplinas e anos letivos. A escolha dos candidatos levou em conta quatro critérios práticos: capacidade de capturar relações não lineares, robustez diante de atributos heterogêneos, custo razoável de treinamento e possibilidade de comparar o desempenho com regras simples de referência.

Algoritmos como regressão linear e árvore de decisão simples seriam mais fáceis de explicar, mas tenderiam a representar de forma limitada interações entre nota anterior, tendência, faltas, pagamentos e contexto escolar. Métodos como Support Vector Machine (SVM) poderiam ser usados, mas costumam exigir maior cuidado com escala, ajuste de hiperparâmetros e interpretação em bases tabulares maiores. Redes neurais profundas, por sua vez, foram consideradas menos aderentes ao volume e à irregularidade das sequências disponíveis. Modelos como CatBoost e LightGBM permanecem como alternativas futuras, mas não foram priorizados na versão final para manter a solução mais simples, reproduzível e apoiada em bibliotecas já consolidadas no ambiente do projeto.

2.3.1 Random Forest

O *Random Forest*, proposto por Breiman (Breiman, 2001), foi importante no projeto por servir como primeiro modelo tabular forte após a fase exploratória. Sua principal vantagem está na robustez em dados tabulares, na capacidade de capturar relações não lineares e na boa tolerância a atributos heterogêneos.

2.3.2 LSTM

As redes Long Short-Term Memory (LSTM), introduzidas por Hochreiter e Schmidhuber (Hochreiter; Schmidhuber, 1997), foram consideradas por causa da natureza temporal do problema. No entanto, a base real revelou sequências irregulares, entradas e saídas de alunos e históricos de extensão muito desigual. Esses fatores reduziram a aderência dessa abordagem ao escopo institucional do trabalho.

2.3.3 Gradient Boosting

O *Gradient Boosting*, formalizado por Friedman (Friedman, 2001), mostrou-se especialmente adequado à solução final por trabalhar bem com dados tabulares

e atributos derivados. A variação *HistGradientBoosting* foi incluída por ser eficiente em bases tabulares e por lidar bem com padrões não lineares. Na rodada final, ele foi o melhor candidato para o modo de alerta de risco, enquanto o *Random Forest* permaneceu competitivo e foi selecionado para a regressão no modo de previsão de nota.

2.3.4 Classificação supervisionada e regras simples

Uma decisão importante foi manter a classificação de risco como tarefa supervisionada, em vez de utilizar apenas regras fixas, como “se a nota prevista for menor que 6, então o aluno está em risco”. Essa regra seria simples, mas perderia parte do comportamento temporal do problema. O aluno pode ter uma nota prevista numericamente próxima da média e, ainda assim, apresentar padrão de queda, histórico anterior fraco na disciplina, faltas acumuladas ou distância negativa em relação à turma. A classificação aprende diretamente com exemplos históricos quais combinações desses sinais antecederam notas futuras abaixo de 6,0.

Isso não elimina as regras. No projeto, regras e pontuações continuam sendo usadas na camada de relatórios e priorização. A diferença é que o alerta principal de risco é estimado por um classificador treinado com dados reais, enquanto as regras ajudam a organizar a comunicação pedagógica e a calibrar prioridades.

2.4 Dados temporais, validade e métricas

Um ponto crítico em aplicações educacionais é a validação temporal. Em vez de dividir aleatoriamente treino e teste, este trabalho adota separação por anos letivos, evitando vazamento entre passado e futuro. Essa decisão aproxima a avaliação do uso real da solução, em que a escola precisa prever o próximo período a partir do passado já conhecido. A preocupação com validação temporal também é discutida em estudos sobre avaliação de modelos em dados dependentes do tempo, nos quais uma divisão aleatória pode produzir estimativas otimistas de desempenho (Bergmeir; Hyndman; Koo, 2018).

As métricas escolhidas acompanham essa dupla natureza do problema. Para regressão, o trabalho utiliza Mean Absolute Error (MAE), que mede o erro médio absoluto em pontos de nota, e Root Mean Squared Error (RMSE), que penaliza erros maiores com mais intensidade. Para classificação de risco, utiliza *precision*, *recall* e F1-score (F1). A *precision* indica, entre os alunos sinalizados, quantos realmente estavam em risco; o *recall* indica, entre os alunos que realmente estavam em risco, quantos foram recuperados pelo modelo; e o F1 combina essas duas medidas.

Essa combinação permite avaliar tanto proximidade numérica quanto capacidade de recuperar casos críticos.

2.5 Ética, privacidade e interpretabilidade

O uso de dados educacionais exige atenção especial à privacidade, à finalidade do tratamento e à interpretação cuidadosa das saídas. Discussões em LA e EDM mostram que proteção de dados e governança não são barreiras para análise, mas condições para seu uso institucionalmente legítimo (Slade; Prinsloo, 2013; Gasevic; Dawson; Jovanovic, 2016; Khalil; Ebner, 2016). No contexto brasileiro, a Lei Geral de Proteção de Dados Pessoais (LGPD) reforça esse cuidado (Brasil, 2018).

Por isso, o projeto incorporou anonimização da base e assumiu, desde o início, que a saída do sistema não poderia ser um veredito definitivo sobre o aluno. Os relatórios foram desenhados para indicar fatores de alerta e recomendações iniciais, preservando o papel humano na decisão pedagógica (Fiok *et al.*, 2022).

2.6 Trabalhos relacionados

Os trabalhos relacionados ao tema podem ser agrupados em três eixos. O primeiro reúne revisões gerais da área, como as de Romero e Ventura (Romero; Ventura, 2010) e de Baker e Inventado (Baker; Inventado, 2014). O segundo eixo envolve estudos preditivos aplicados à educação, sobretudo aqueles que combinam múltiplas fontes de informação. O terceiro eixo aborda interpretabilidade, governança e questões éticas.

Em relação a esses trabalhos, este TCC se diferencia por articular toda a trajetória de um projeto aplicado: tratamento do banco, refatoração arquitetural, validação temporal, geração de relatórios e ranking executivo. Em vez de comparar apenas algoritmos em um *dataset* pronto, o trabalho documenta a construção completa de uma solução voltada ao contexto escolar.

Materiais, Métodos e Evolução do Projeto

3.1 Natureza da pesquisa

Esta pesquisa é aplicada, predominantemente quantitativa e com forte componente tecnológico-experimental. É aplicada porque busca resolver um problema concreto de acompanhamento escolar. É quantitativa porque trabalha com dados históricos estruturados, métricas preditivas e validação temporal. E é tecnológica porque envolve a construção efetiva de software, rotinas de extração, pipeline de modelagem e relatórios operacionais.

3.2 Fonte de dados e preparo inicial

Os dados utilizados são provenientes de uma base escolar real contendo registros de alunos, notas, faltas, pagamentos e informações acadêmicas e administrativas. A base institucional foi renovada com registros de 2026 e passou por um processo de manutenção para uso acadêmico. Esse fluxo incluiu renomeação da base, redução estrutural, reorganização de índices, atualização de estatísticas e anonimização dos registros sensíveis. Como a avaliação temporal depende de conhecer a próxima nota observada, os experimentos finais utilizaram 2025 como ano de teste consolidado; dados de 2026 permanecem relevantes para continuidade operacional, mas nem sempre possuem alvo futuro completo para avaliação experimental.

Os arquivos principais extraídos para a pipeline foram:

- `aluno.csv`;
- `media_nota_aluno.csv`;
- `faltas_aluno.csv`;
- `pagamento_aluno.csv`;
- `responsaveis_aluno.csv`;

- `professor_disciplina.csv`, quando o vínculo docente estava disponível.

3.3 Estratégia metodológica

O trabalho foi conduzido de forma incremental. Em vez de partir diretamente para uma solução final, o projeto foi sendo refinado em ciclos de exploração, teste, diagnóstico de limitações e refatoração. Esse percurso não foi um desvio do objetivo do TCC; ao contrário, ele mostrou quais escolhas se sustentavam diante do problema real.

Para organizar a apresentação desse percurso, também foi adotada uma leitura inspirada no ciclo Cross-Industry Standard Process for Data Mining (CRISP-DM) (Wirth; Hipp, 2000). Assim, o projeto pode ser compreendido em seis movimentos: entendimento do problema escolar, entendimento dos dados, preparação da base, modelagem, avaliação e disponibilização dos resultados em relatórios e painel. Essa estrutura foi usada como material demonstrativo nos notebooks do repositório, sem substituir a arquitetura de produção da aplicação.

3.4 Evolução histórica do projeto

3.4.1 Fase inicial orientada a grafo

O projeto começou com uma hipótese baseada em grafos heterogêneos, motivada pela natureza relacional do domínio escolar. Nessa etapa, foram produzidos módulos para leitura de entidades, construção de relações e consultas em estruturas relacionais. A ideia era representar alunos, matrículas, disciplinas, responsáveis, faltas e pagamentos como nós e arestas.

3.4.2 Fase exploratória com testes clássicos e PCA

Na sequência, o projeto incorporou análises estatísticas e testes com classificadores tradicionais, além de redução exploratória de dimensionalidade com Principal Component Analysis (PCA). Essa fase foi importante para entender a distribuição dos atributos e perceber que o problema exigia mais do que uma base estática pivotada.

3.4.3 Fase temporal com LSTM

Como o problema possui natureza temporal, foi investigada também uma abordagem sequencial com Long Short-Term Memory (LSTM). Apesar de conceitu-

almente promissora, essa alternativa não se consolidou, sobretudo por depender de sequências mais homogêneas e longas do que as observadas na base.

3.4.4 Fase tabular com Random Forest

Posteriormente, o projeto migrou para um desenho mais pragmático com *Random Forest*. Essa fase representou um avanço importante por aproximar a solução de um problema tabular supervisionado. Ainda assim, permaneceram limitações relacionadas ao pivotamento excessivo, perda de temporalidade e uso incompleto de dados como faltas e pagamentos.

3.4.5 Refatoração para pipeline real

O amadurecimento do trabalho levou primeiro à consolidação de uma pipeline intermediária de experimentação, e depois à arquitetura final entregue no pacote `school_predictor`. Essa arquitetura separou explicitamente:

- a camada de acesso e conexão com o banco;
- a preparação física e anonimização do banco restaurado;
- a extração dos dados para arquivos canônicos;
- a pipeline de modelagem e relatórios;
- a camada de visualização em dashboard.

Na versão final do repositório, a aplicação pública foi organizada em torno de `school_predictor/`, enquanto as consultas SQL reais e as rotinas detalhadas de operação com o banco passaram a ficar em uma camada local privada, fora do Git. Essa decisão tornou a solução mais adequada à publicação acadêmica, sem expor o desenho interno do banco institucional.

3.5 Critérios de avaliação

Os critérios de avaliação foram definidos em duas camadas. A primeira camada é estatística e envolve *MAE*, *RMSE*, *precision*, *recall* e *F1*. A segunda camada é institucional e pergunta se a solução consegue priorizar casos urgentes, gerar relatórios compreensíveis e apoiar diferentes atores escolares. Essa combinação foi necessária porque um modelo matematicamente competente nem sempre é automaticamente útil para a escola.

Arquitetura da Solução e Integração dos Dados

4.1 Visão geral da arquitetura

A arquitetura final foi organizada para separar claramente as responsabilidades do sistema. O fluxo consolidado pode ser resumido em oito etapas:

1. manutenção e anonimização da base original;
2. extração das tabelas relevantes para arquivos Comma-Separated Values (CSV);
3. leitura estruturada dessas fontes pela pipeline;
4. construção do dataset longitudinal;
5. separação temporal entre treino, validação e teste;
6. comparação automática entre modelos e baselines;
7. geração de previsões e análises de erro;
8. produção de relatórios operacionais para a escola.


Em termos de organização do código, o núcleo da solução ficou distribuído entre módulos de configuração, leitura das fontes, engenharia de atributos, modelagem, relatórios e orquestração.

Na versão final do repositório, essa organização foi consolidada no pacote `school_predictor/`, com artefatos locais centralizados em `artifacts/`. Essa separação tornou a arquitetura mais simples de compreender e mais segura para publicação do código.

4.2 Modos de execução

A pipeline foi dividida em dois modos complementares:

- `previsao_nota`: voltado à regressão da próxima nota, com histórico mínimo de uma observação anterior por disciplina;


Figura 1 – *Visão arquitetural da solução proposta.*

Fonte: Elaborada pelo autor..

- **alerta_risco**: voltado à classificação de risco de próxima nota abaixo de 6,0, com histórico mínimo de duas observações anteriores.

Essa divisão surgiu dos experimentos: o mesmo recorte de histórico não era o melhor para os dois objetivos. Assim, a arquitetura passou a preservar duas configurações operacionais, cada uma adequada ao seu uso principal.

Em ambos os modos, a função central de modelagem calcula sinais de regressão e de classificação. A diferença está no objetivo operacional, no histórico mínimo exigido, no volume de dados resultante e no artefato usado como referência principal. No modo **previsao_nota**, a interpretação principal é o erro da nota prevista; no modo **alerta_risco**, a interpretação principal é a capacidade de recuperar alunos cuja próxima nota ficou abaixo da linha de segurança.

Figura 2 – *Fluxo operacional da pipeline de modelagem.*

Fonte: Elaborada pelo autor..

4.3 Integração de notas, faltas, pagamentos e professores

O trabalho foi estruturado para unir quatro blocos principais de informação:

- desempenho acadêmico;
- frequência;

- sinais administrativos e financeiros;
- contexto escolar, incluindo disciplina, série, turma e professor.

Do ponto de vista de engenharia, a entrada de dados foi organizada em duas camadas. A primeira camada é privada e local, responsável pela preparação do banco restaurado e pela execução das consultas SQL reais. A segunda camada é pública e reproduzível, baseada nos arquivos **CSV** canônicos consumidos pela pipeline em **artifacts/database/csv/**. Isso permite explicar e reproduzir a arquitetura sem divulgar a estrutura interna do banco institucional.

As notas representam o eixo central da modelagem. A partir delas, foram construídos históricos deslocados, médias móveis, tendências e estatísticas de referência. As faltas foram agregadas por etapa e acumuladas ao longo do tempo. Os pagamentos foram resumidos por ano letivo, incluindo quantidades, pendências e médias de atraso. O professor, quando disponível no banco atualizado, passou a ser incorporado como atributo contextual, sem remover linhas quando o vínculo docente estivesse ausente.

4.4 Engenharia de atributos

Os atributos criados para a modelagem incluem:

- nota anterior 1, 2 e 3;
- média das últimas notas;
- desvio histórico da disciplina;
- tendência da última nota;
- média histórica do aluno no ano;
- média do aluno no ano anterior;
- média da disciplina no ano anterior;
- média da coorte por etapa;
- faltas da etapa;
- faltas acumuladas;
- pagamentos realizados e pendentes no ano;
- dias até pagamento;
- indicador de disponibilidade do professor.

Todos esses atributos foram construídos usando apenas informação disponível até o ponto da previsão, preservando a causalidade temporal do problema.

4.5 Construção do alvo e prevenção de vazamento

Foram definidos dois alvos principais:

1. `target_nota_proxima`, correspondente ao valor numérico da próxima nota observada;
2. `target_risco_proxima`, correspondente ao indicador binário de próxima nota inferior a 6,0.

Para evitar vazamento de informação, os atributos históricos foram calculados por deslocamento, médias acumuladas ou agregações limitadas ao passado. Isso foi essencial para garantir que o desempenho medido refletisse um cenário real de uso, e não apenas um ajuste artificial a dados futuros.

4.6 Camada de relatórios

Além da modelagem, a arquitetura incorpora uma camada própria de relatórios com quatro saídas principais:

- relatório do professor, com foco por aluno e disciplina;
- relatório da coordenação, com agregados por série e disciplina;
- relatório da secretaria, com ênfase administrativa;
- ranking executivo de alunos prioritários.

Essa camada foi decisiva para aproximar a solução do problema real da escola, convertendo resultados técnicos em informação acionável.

4.7 Estrutura final do repositório e do fluxo operacional

Na forma final do projeto, a base ativa do software ficou organizada nos seguintes blocos:

- `school_predictor/database`: acesso ao banco, wrappers públicos de preparação e extração, e contrato das consultas;
- `school_predictor/database/private_runtime.py`: camada local privada para preparação física do banco e extração com tratamento sensível;
- `school_predictor/database/private_sql/`: consultas SQL reais mantidas apenas no ambiente local;

- `school_predictor/pipeline`: construção do dataset, modelagem, avaliação e relatórios;
- `school_predictor/app`: dashboard em Streamlit;
- `artifacts/database/csv`: interface canônica de entrada da pipeline;
- `artifacts/pipeline` e `artifacts/reports`: saídas analíticas e operacionais.

Com isso, a arquitetura final passou a separar claramente o que precisa ficar privado por envolver estrutura institucional do banco e o que pode ser publicado para fins acadêmicos, reprodutibilidade e apresentação do TCC.

Modelagem, Relatórios e Resultados

5.1 Modelos candidatos e critérios de seleção

A etapa de modelagem comparou candidatos de regressão, candidatos de classificação e baselines determinísticos. Essa organização foi importante porque o objetivo não era apenas treinar um algoritmo sofisticado, mas verificar se ele realmente acrescentava valor em relação a regras simples baseadas no próprio histórico de notas.

Os candidatos avaliados foram:

- *RandomForestRegressor* e *RandomForestClassifier*;
- *HistGradientBoostingRegressor* e *HistGradientBoostingClassifier*;
- baseline de última nota;
- baseline de média das duas últimas notas;
- baseline de média das três últimas notas;
- baseline híbrido.

Para regressão, o critério principal de seleção foi o Mean Absolute Error (MAE). Para classificação de risco, o critério principal foi o F1-score (F1), acompanhado de *precision* e *recall*. O MAE foi escolhido porque expressa o erro diretamente em pontos de nota, o que facilita a interpretação pedagógica. O F1 foi usado porque equilibra a capacidade de encontrar casos críticos com a precisão dos alertas emitidos.

5.2 Comparação dos candidatos na validação

A Tabela 1 mostra a comparação dos principais candidatos de regressão na etapa de validação. No modo de previsão de nota, o *Random Forest* foi ligeiramente superior ao *HistGradientBoosting* em MAE, por isso foi selecionado como regressor principal desse modo. No modo de alerta de risco, por outro lado, o *HistGradientBoosting* foi o melhor regressor dentro do recorte com histórico mínimo maior.

Tabela 1 – *Comparação dos candidatos de regressão na validação.*

Modo e candidato	MAE	RMSE	Erro $\leq 0,5$	Fonte: Elaborada pelo autor com base nos artefatos da pipeline..
Previsão – Random Forest	0,8152	1,0907	0,4261	
Previsão – HistGradientBoosting	0,8191	1,0926	0,4156	
Previsão – baseline de última nota	0,9148	1,3015	0,4531	
Alerta – HistGradientBoosting	0,8124	1,1113	0,4429	
Alerta – Random Forest	0,8327	1,1167	0,4174	
Alerta – baseline de duas notas	0,9196	1,2746	0,4248	

A Tabela 2 apresenta a comparação dos candidatos de classificação para risco. O resultado mostra duas evidências importantes. Primeiro, baselines simples ainda são competitivos e precisam ser considerados. Segundo, no modo especificamente calibrado para alerta de risco, o *HistGradientBoostingClassifier* superou os demais candidatos em F1.

Tabela 2 – *Comparação dos candidatos de classificação na validação.*

Modo e candidato	Precision	Recall	F1	Fonte: Elaborada pelo autor com base nos artefatos da pipeline..
Previsão – baseline de duas notas	0,7011	0,7744	0,7359	
Previsão – HistGradientBoosting	0,6172	0,8937	0,7302	
Previsão – Random Forest	0,5743	0,9158	0,7059	
Alerta – HistGradientBoosting	0,6980	0,8255	0,7564	
Alerta – baseline de duas notas	0,7165	0,7908	0,7518	
Alerta – Random Forest	0,6091	0,9036	0,7277	

5.3 Resultados do modo de previsão de nota

No modo `previsao_nota`, o melhor cenário foi obtido com histórico mínimo igual a 1. A base de modelagem alcançou 106.721 linhas, 1.378 alunos únicos, 53 disciplinas e 6 anos letivos considerados. O conjunto temporal foi organizado com treino em anos anteriores, validação em 2024 e teste em 2025.

O melhor candidato de regressão foi o *RandomForestRegressor*, com os resultados finais apresentados na Tabela 3. Em termos práticos, isso significa que a

previsão da próxima nota ficou, em média, a aproximadamente 0,77 ponto da nota realmente observada, superando a heurística simples de repetir a nota anterior.

Tabela 3 – *Resultados finais do modo de previsão de nota no teste temporal.*

Métrica	Valor	
MAE do modelo	0,7659	
RMSE do modelo	1,0519	Fonte: Elaborada pelo autor com base nos
Acerto com erro $\leq 0,5$	0,4649	
MAE do baseline de última nota	0,9138	
RMSE do baseline de última nota	1,2967	
artefatos da pipeline..		

5.4 Resultados do modo de alerta de risco

No modo `alerta_risco`, o melhor cenário foi obtido com histórico mínimo igual a 2. Nessa configuração, a base de modelagem alcançou 50.065 linhas, 1.179 alunos únicos e 53 disciplinas. O melhor classificador foi o *HistGradientBoosting-Classifier*, com os resultados apresentados na Tabela 4.

Tabela 4 – *Resultados finais do modo de alerta de risco no teste temporal.*

Métrica	Valor	
Precision do modelo	0,6442	
Recall do modelo	0,8794	Fonte: Elaborada pelo autor com base nos artefatos da
F1 do modelo	0,7436	
F1 do baseline	0,7243	
pipeline..		

O destaque está no *recall*. Em um sistema de alerta, perder casos realmente críticos tende a ser mais grave do que sinalizar alguns casos adicionais para acompanhamento. Por isso, esse resultado foi considerado adequado ao objetivo pedagógico do trabalho: priorizar alunos que merecem revisão humana, não produzir uma decisão automática.

A Tabela 5 resume a matriz de confusão do modo de alerta de risco no teste temporal. Dos 2.794 casos que realmente tiveram próxima nota abaixo de 6,0,

o modelo recuperou 2.457. Por outro lado, também sinalizou 1.357 casos que não se confirmaram como risco no alvo observado. Esse comportamento é coerente com uma ferramenta de triagem, pois privilegia cobertura dos casos críticos.

Tabela 5 – *Matriz de confusão do alerta de risco no teste temporal.*

Risco real	Predito sem risco	Predito com risco
Sem risco	9.092	1.357
Com risco	337	2.457

autor com base nos artefatos da pipeline..

Fonte: Elaborada pelo

5.5 Comparando históricos mínimos

Os testes de histórico mínimo mostraram um resultado relevante para a arquitetura do projeto:

- `min_history = 1` foi melhor para regressão da próxima nota, pois preservou mais alunos e disciplinas na base;
- `min_history = 2` foi melhor para classificação de risco, pois exigiu maior evidência histórica antes de sinalizar alerta;
- `min_history = 3` reduziu demais a quantidade de casos e inviabilizou a validação temporal na rodada analisada.

Essa evidência levou à separação da pipeline em dois modos complementares de uso, cada um com sua configuração mais adequada.

5.6 Exemplo interpretado de alerta

A Tabela 6 apresenta um caso pseudonimizado retirado dos artefatos de teste. O exemplo é útil porque mostra por que o projeto manteve um classificador de risco, e não apenas uma regra baseada na nota prevista.

Se o sistema usasse apenas a regra “nota prevista menor que 6”, esse caso não seria sinalizado, pois a previsão numérica foi 6,58. O classificador, entretanto, identificou o risco a partir do conjunto de sinais: histórico anterior fraco na disciplina, média recente abaixo da linha de segurança, faltas acumuladas e desempenho abaixo da média da coorte. Esse exemplo mostra que a regressão e a classificação são complementares.

Tabela 6 – *Exemplo pseudonimizado de caso sinalizado pelo alerta de risco.*

Campo	Valor observado
Aluno, série e disciplina	Aluno 01790, 1ª Série, Biologia 2
Etapa analisada	3º bimestre de 2025
Nota atual e próxima nota real	6,3 na etapa atual; 5,8 na etapa seguinte
Notas anteriores na disciplina	5,5 e 4,5
Média das duas últimas notas	5,0
Faltas acumuladas	7 faltas até a etapa analisada
Pagamentos pendentes no ano	0 pendências registradas
Média da coorte na etapa	6,98
Professor vinculado	Professor 00019
Nota prevista pelo regressor	6,58
Alerta do classificador	Risco sinalizado corretamente

Fonte: Elaborada pelo autor com base nos artefatos da pipeline..

5.7 Geração de relatórios escolares

Os resultados preditivos não foram o ponto final da solução. A partir deles, o projeto passou a gerar relatórios para três perfis institucionais:

- professor: com nota atual, nota prevista, fatores de alerta e recomendação pedagógica;
- coordenação: com visão por série, disciplina, ranking executivo e consolidados por professor;
- secretaria: com sinais administrativos relacionados a frequência, financeiro e prioridade de contato.

Também foram construídos relatórios por professor, incluindo consolidados por turma e consolidados gerais, com contagem de alunos em risco baixo, moderado e alto. Essa camada aproxima a modelagem do cotidiano escolar, pois transforma erro, probabilidade e predição em informação compreensível por cada perfil de uso.

5.8 Análise de erro e calibração

A análise de erro mostrou maior dificuldade de previsão em disciplinas como Matemática 3, Matemática 4 e 5, Biologia 2, História 2 e Química 3. Também houve

maior erro nas faixas de nota abaixo de 7, especialmente porque esses casos são mais instáveis e pedagogicamente mais sensíveis.

Tabela 7 – *Principais pontos de erro no modo de alerta de risco.*

Grupo analisado	Amostras	MAE	Acurácia de risco
Matemática 4 e 5	81	1,9489	0,7778
Biologia 2	260	1,5895	0,6500
História 2	81	1,3741	0,6667
Faixa abaixo de 6	2.794	1,0395	0,8794
Faixa de 6 a 6,99	1.405	0,9718	0,5103

Fonte: Elaborada pelo autor

com base nos artefatos da pipeline..

Na camada operacional, a primeira regra de risco gerava excesso de casos classificados como alto risco. Por isso, foi criada uma pontuação composta que passou a combinar:

- predição de risco do modelo;
- nota prevista;
- nota atual;
- variação esperada;
- faltas acumuladas;
- pendências financeiras.

Com essa calibração, a priorização ficou mais compatível com o uso institucional, reduzindo sobrecarga sobre coordenação e professores. Assim, a saída final do sistema não deve ser lida como sentença sobre o aluno, mas como convite estruturado à investigação pedagógica.

Discussão, Limitações e Conclusão

6.1 Discussão dos resultados

Os resultados mostram que a solução final apresenta aderência melhor ao problema do que as hipóteses iniciais do projeto. Embora grafos e *LSTM* tenham sido importantes na fase exploratória, a experiência empírica indicou que o problema central estava melhor representado por uma base tabular temporal com atributos derivados e validação cronológica.

Outro ponto importante é o valor dos baselines. Em diferentes momentos do trabalho, regras simples baseadas na última nota ou em médias móveis competiram de forma relevante com modelos mais sofisticados. Isso reforça que complexidade algorítmica não deve ser tomada como sinônimo automático de superioridade.

Do ponto de vista institucional, o maior avanço do projeto não está apenas nas métricas, mas na passagem da predição para a ação. O valor do sistema aparece quando a nota prevista, o alerta de risco e os sinais complementares são convertidos em relatórios inteligíveis para professor, coordenação e secretaria. Na prática, esses alertas devem orientar investigação pedagógica, priorização de contato, planejamento de reforço e acompanhamento da evolução do aluno.

6.2 Limitações do trabalho

As principais limitações identificadas foram:

1. o vínculo de professor ainda não cobre integralmente todo o histórico analisado;
2. o ranking executivo ainda concentra muitos casos nas faixas mais altas de prioridade;
3. a base de 2026 já existe, mas nem todos os cenários possuem alvo consolidado suficiente para teste completo;
4. o projeto utiliza variáveis institucionais disponíveis, mas não incorpora dimensões qualitativas, socioemocionais ou contextuais mais profundas;

5. a generalização para outras escolas exige adaptação local da arquitetura e nova validação.

Também existem ameaças à validade interna, externa e de construção. Nem toda queda de desempenho é explicada pelas variáveis disponíveis, e conceitos educacionais complexos acabam representados por *proxies* quantitativos, como faltas, pagamentos e trajetória de notas.

6.3 Conclusão

Este Trabalho de Conclusão de Curso apresentou o desenvolvimento de um sistema preditivo para apoio à decisão pedagógica com base em dados escolares reais. O projeto evoluiu de uma hipótese inicial orientada a grafos para uma pipeline temporal tabular reproduzível, capaz de:

- prever a próxima nota do aluno com desempenho superior a baselines simples;
- identificar risco de nota futura abaixo de 6 com *recall* elevado;
- integrar notas, faltas, pagamentos e contexto escolar em uma arquitetura única;
- transformar resultados técnicos em relatórios operacionais para diferentes atores da escola.

Em termos quantitativos, o modo de previsão numérica atingiu *MAE* de 0,7659, enquanto o modo de alerta de risco alcançou *F1* de 0,7436 e *recall* de 0,8794 no teste temporal. Em termos práticos, esses resultados indicam que a solução já pode servir como mecanismo de triagem e priorização institucional, desde que usada com supervisão humana e interpretação contextualizada.

Assim, a principal contribuição do trabalho não está apenas em acertar melhor uma nota futura, mas em mostrar que é possível construir uma arquitetura analítica coerente com o cotidiano da escola, eticamente defensável e operacionalmente útil.

6.4 Trabalhos futuros

Como continuidade natural do projeto, destacam-se os seguintes desdobramentos:

1. ampliar a cobertura do vínculo com professores;
2. recalibrar os limiares do ranking executivo;

3. incorporar técnicas adicionais de explicabilidade;
4. avaliar o impacto real dos relatórios na rotina escolar;
5. testar novos modelos tabulares, como CatBoost e LightGBM;
6. investigar variáveis qualitativas e socioemocionais;
7. validar a solução em outras escolas ou redes.

Referências

BAKER, Ryan S. J. d.; INVENTADO, Paulo S. Educational data mining and learning analytics. *In*: LARUSSON, Johann Ari; WHITE, Brandon (Ed.). **Learning Analytics: From Research to Practice**. New York: Springer, 2014. p. 61–75. 10, 12, 15

BERGMEIR, Christoph; HYNDMAN, Rob J.; KOO, Bonsoo. A note on the validity of cross-validation for evaluating autoregressive time series prediction. **Computational Statistics & Data Analysis**, v. 120, p. 70–83, 2018. 14

Brasil. **Lei nº 13.709, de 14 de agosto de 2018**. 2018. Lei Geral de Proteção de Dados Pessoais. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 21 abr. 2026. 15

BREIMAN, Leo. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. 13

FIOK, Krzysztof; KARWOWSKI, Waldemar; GUTIERREZ, Eduardo; WILAMOWSKI, Bogdan; REZA, Ali; AHRAM, Tareq. Explainable artificial intelligence for education and training. **Human Factors in Emerging Technologies and Society**, v. 19, n. 2, 2022. 15

FRIEDMAN, Jerome H. Greedy function approximation: A gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001. 13

GASEVIC, Dragan; DAWSON, Shane; JOVANOVIĆ, Jelena. Ethics and privacy as enablers of learning analytics. **Journal of Learning Analytics**, v. 3, n. 1, p. 1–4, 2016. 15

HOCHREITER, Sepp; SCHMIDHUBER, Jürgen. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. 13

KHALIL, Mohammad; EBNER, Martin. De-identification in learning analytics. **Journal of Learning Analytics**, v. 3, n. 1, p. 129–138, 2016. 15

ROMERO, Cristóbal; VENTURA, Sebastián. Educational data mining: A review of the state of the art. **IEEE Transactions on Systems, Man, and Cybernetics, Part C**, v. 40, n. 6, p. 601–618, 2010. 10, 12, 15

ROMERO, Cristóbal; VENTURA, Sebastián; PECHENIZKIY, Mykola; BAKER, Ryan S. J. d. (Ed.). **Handbook of Educational Data Mining**. Boca Raton: CRC Press, 2010. 12

SIEMENS, George; BAKER, Ryan S. J. d. Learning analytics and educational data mining: Towards communication and collaboration. *In: Proceedings of the 2nd International Conference on Learning Analytics and Knowledge*. New York: ACM, 2012. p. 252–254. 10, 12

SLADE, Sharon; PRINSLOO, Paul. Learning analytics: Ethical issues and dilemmas. **American Behavioral Scientist**, v. 57, n. 10, p. 1510–1529, 2013. 15

WIRTH, Rüdiger; HIPPE, Jochen. **CRISP-DM: Towards a Standard Process Model for Data Mining**. Manchester: [s.n.], 2000. 17

Apêndice A – Estrutura resumida da solução

Este apêndice resume os principais blocos do repositório utilizados pela versão final do TCC.

A.1 Organização do repositório

- `school_predictor`: base ativa da aplicação final;
- `artifacts`: entrada e saída canônicas da pipeline no ambiente local;
- `docs`: documentação textual do projeto e apoio à defesa;
- `monografia`: projeto LaTeX da monografia e do pré-projeto;
- `diagrama`: diagramas da arquitetura e do fluxo de modelagem.

A.2 Módulos centrais da pipeline

`school_predictor/database/access.py` define a conexão com o banco por variáveis de ambiente;

`school_predictor/database/maintenance.py` expõe o wrapper público da preparação do banco;

`school_predictor/database/extraction.py` expõe o wrapper público da extração;

`school_predictor/database/private_runtime.py` concentra localmente as etapas privadas de preparação e extração;

`school_predictor/pipeline/dataset.py` constrói o dataset longitudinal e a engenharia de atributos;

`school_predictor/pipeline/modeling.py` realiza a validação temporal, seleção de candidatos e avaliação;

`school_predictor/pipeline/reporting.py` produz os relatórios para professor, coordenação e secretaria;

`school_predictor/cli.py` orquestra a operação principal do projeto.

A.3 Artefatos principais gerados

Entre os principais artefatos produzidos pela pipeline estão:

- arquivos CSV em `artifacts/database/csv`;
- relatórios técnicos de `previsao_nota` e `alerta_risco`;
- arquivos de predição por modo;
- análises de erro por disciplina, série e faixa de nota;
- relatórios escolares para professor, coordenação e secretaria;
- ranking executivo da coordenação;
- painel em Streamlit para visualização operacional.